Московский государственный технический университет им. Н.Э. Баумана
Факультет «Информатика и системы управления»
Кафедра «Системы обработки информации и управления»

Рубежный контроль №1

«Методы обработки данных»

по дисциплине

«Методы машинного обучения»

ИСПОЛНИТЕЛЬ:

Крюков Г.М.
Группа ИУ5-21М
_____

"__"_____2022 г.

ПРОВЕРИЛ:

Гапанюк Ю.Е.
_____

"__"_____2022 г.

Москва, 2022

Вариант работы:

Крюков Геннадий ИУ5-21М

Номер по списку группы – 6

Вариант задачи №1 - 6

Для набора данных проведите устранение пропусков для одного (произвольного) числового признака с использованием метода заполнения средним значением.

Вариант задачи №2 - 26

Для набора данных для одного (произвольного) числового признака проведите обнаружение и замену (найденными верхними и нижними границами) выбросов на основе правила трех сигм.

Дополнительное задание

Для пары произвольных колонок данных построить график "Диаграмма рассеяния".

Набор данных:

This dataset is used to predict whether a patient is likely to get stroke based on the input parameters like gender, age, various diseases, and smoking status. Each row in the data provides relevant information about the patient.

Поля:

id: unique identifier

gender: "Male", "Female" or "Other"

age: age of the patient

hypertension: 0 if the patient doesn't have hypertension, 1 if the patient has hypertension

heart_disease: 0 if the patient doesn't have any heart diseases, 1 if the patient has a heart

disease

ever_married: "No" or "Yes"

work_type: "children", "Govt_jov", "Never_worked", "Private" or "Self-employed"

Residence_type: "Rural" or "Urban"

avg_glucose_level: average glucose level in blood

bmi: body mass index

smoking_status: "formerly smoked", "never smoked", "smokes" or "Unknown"*

stroke: 1 if the patient had a stroke or 0 if not

"Unknown" in smoking_status means that the information is unavailable for this patient

Текст программы:

```
[ ] import numpy as np
    import pandas as pd
    import matplotlib.pyplot as plt
    import seaborn as sns
    import scipy.stats as stats
```

```
[ ] data = pd.read_csv('/Users/user/Downloads/stroke.csv')
```

```
[ ] data.head()
```

	id	gender	age	hypertension	heart_disease	ever_married	work_type	Residence_type	avg_glucose_level	bmi	smoking_status	stroke
0	9046	Male	NaN	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked	1
1	51676	Female	61.0	0	0	Yes	Self-employed	Rural	202.21	NaN	never smoked	1
2	31112	Male	80.0	0	1	Yes	Private	Rural	105.92	32.5	never smoked	1
3	60182	Female	49.0	0	0	Yes	Private	Urban	171.23	34.4	smokes	1
4	1665	Female	NaN	1	0	Yes	Self-employed	Rural	174.12	24.0	never smoked	1

```
[ ] data = data.drop('id', 1)
    data.head()
```

	gender	age	hypertension	heart_disease	ever_married	work_type	Residence_type	avg_glucose_level	bmi	smoking_status	stroke
0	Male	NaN	0	1	Yes	Private	Urban	228.69	36.6	formerly smoked	1
1	Female	61.0	0	0	Yes	Self-employed	Rural	202.21	NaN	never smoked	1
2	Male	80.0	0	1	Yes	Private	Rural	105.92	32.5	never smoked	1
3	Female	49.0	0	0	Yes	Private	Urban	171.23	34.4	smokes	1
4	Female	NaN	1	0	Yes	Self-employed	Rural	174.12	24.0	never smoked	1

Задача 1 (6)

Для набора данных проведите устранение пропусков для одного (произвольного) числового признака с использованием метода заполнения средним значением.

```
[ ] data_features = list(zip(
    # признаки
    [i for i in data.columns],
    zip(
        # типы колонок
        [str(i) for i in data.dtypes],
        # проверим есть ли пропущенные значения
        [i for i in data.isnull().sum()]
    )))
    # Признаки с типом данных и количеством пропусков
    data_features
```

```
[('gender', ('object', 0)),
 ('age', ('float64', 16)),
 ('hypertension', ('int64', 0)),
 ('heart_disease', ('int64', 0)),
 ('ever_married', ('object', 0)),
 ('work_type', ('object', 0)),
 ('Residence_type', ('object', 0)),
 ('avg_glucose_level', ('float64', 0)),
 ('bmi', ('float64', 201)),
 ('smoking_status', ('object', 0)),
 ('stroke', ('int64', 0))]
```

```
[ ]  # Доля (процент) пропусков
     [(c, data[c].isnull().mean()) for c in data.columns]
```

```
[('gender', 0.0),
 ('age', 0.0031311154598825833),
 ('hypertension', 0.0),
 ('heart_disease', 0.0),
 ('ever_married', 0.0),
 ('work_type', 0.0),
 ('Residence_type', 0.0),
 ('avg_glucose_level', 0.0),
 ('bmi', 0.03933463796477495),
 ('smoking_status', 0.0),
 ('stroke', 0.0)]
```

Видно, что пропуски имеются в полях age и bmi

+ Код

```
[ ]  # Заполним пропуски bmi средними значениями
     def impute_na(df, variable, value):
         df[variable].fillna(value, inplace=True)
     impute_na(data, 'bmi', data['bmi'].mean())
```

```
[ ]  # Удалим данные, где возраст незаполнен, так как таких данных мало, и удаление не повлияет на качество модели
     data.dropna(subset=['age'], inplace=True)
```

```
[ ]  # Убедимся что нет пустых значений
     data.isnull().sum()
```

```
gender              0
age                 0
hypertension        0
heart_disease       0
ever_married        0
work_type           0
Residence_type      0
avg_glucose_level   0
bmi                 0
smoking_status      0
stroke              0
dtype: int64
```

Итого: Провели устранение пропусков в полях Age - возраст и bmi - индекс массы тела

Задача 2 (26)

Для набора данных для одного (произвольного) числового признака проведите обнаружение и замену (найденными верхними и нижними границами) выбросов на основе правила трех сигм.

```
[ ]  def diagnostic_plots(df, variable, title):
         fig, ax = plt.subplots(figsize=(10,7))
         # гистограмма
         plt.subplot(2, 2, 1)
         df[variable].hist(bins=30)
         ## Q-Q plot
         plt.subplot(2, 2, 2)
         stats.probplot(df[variable], dist="norm", plot=plt)
         # ящик с усами
         plt.subplot(2, 2, 3)
         sns.violinplot(x=df[variable])
         # ящик с усами
         plt.subplot(2, 2, 4)
         sns.boxplot(x=df[variable])
         fig.suptitle(title)
         plt.show()
```

```
[ ]  diagnostic_plots(data, 'bmi', 'bmi')
```

```
/anaconda3/lib/python3.6/site-packages/scipy/stats/stats.py:1706: FutureWarning: Using a n
  return np.add.reduce(sorted[indexer] * weights, axis=axis) / sumval
```

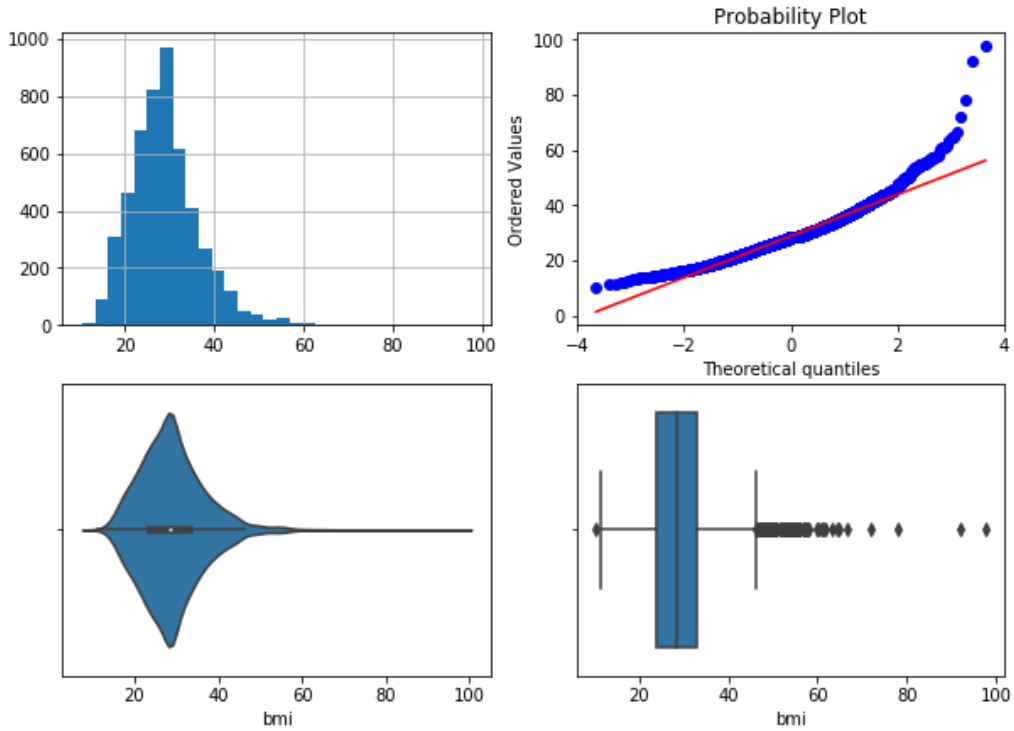

На графике "Ящик с усами" видно, что много выбросов с левой стороны, утсраним их заменой

```
[ ]  lower_boundary = data['bmi'].mean() - (3 * data['bmi'].std())
     upper_boundary = data['bmi'].mean() + (3 * data['bmi'].std())
     print('Нижняя граница',lower_boundary)
     print('Верхняя граница', upper_boundary)
```

```
Нижняя граница 5.793361987638505
Верхняя граница 51.97972296813664
```

```
[ ]  col = 'bmi'
     data[col] = np.where(data[col] > upper_boundary, upper_boundary,
                                     np.where(data[col] < lower_boundary, lower_boundary, data[col]))
     diagnostic_plots(data, col, title)
```

```
/anaconda3/lib/python3.6/site-packages/scipy/stats/stats.py:1706: FutureWarning: Using a non-tuple
  return np.add.reduce(sorted[indexer] * weights, axis=axis) / sumval
```

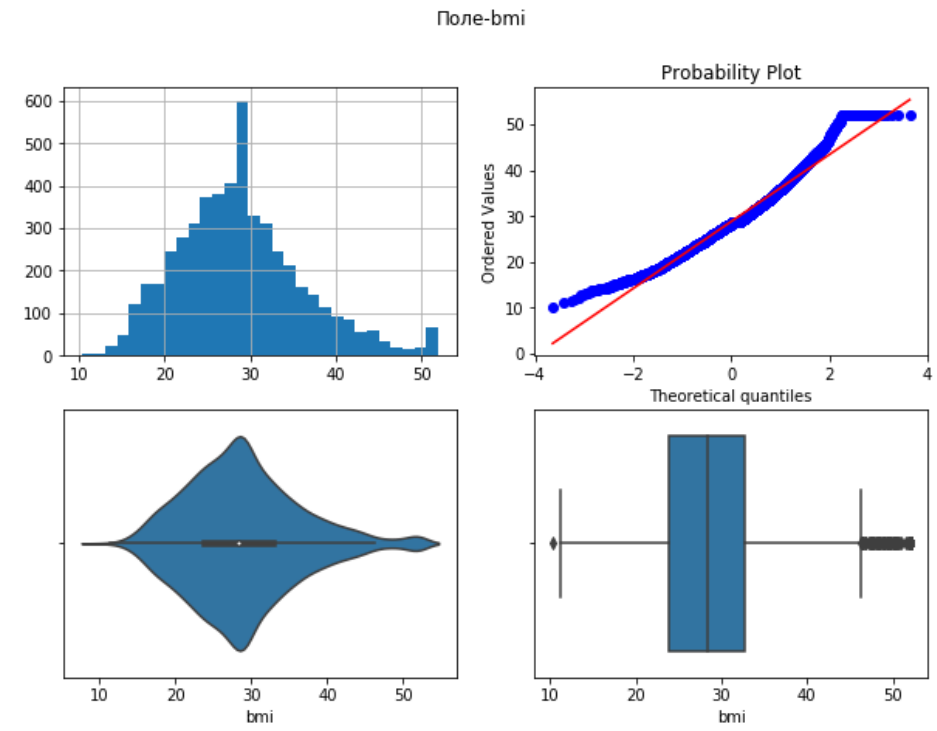

Видно, что количество выбросов уменьшилось, но некоторое количество всё же осталось.

Дополнительное задание

Для пары произвольных колонок данных построить график "Диаграмма рассеяния".

```
[ ]  sns.regplot(x=data['bmi'], y=data['avg_glucose_level'])
```

```
/anaconda3/lib/python3.6/site-packages/scipy/stats/stats.py:1706: FutureWarning: Using
  return np.add.reduce(sorted[indexer] * weights, axis=axis) / sumval
<matplotlib.axes._subplots.AxesSubplot at 0x1a1e9fcef0>
```

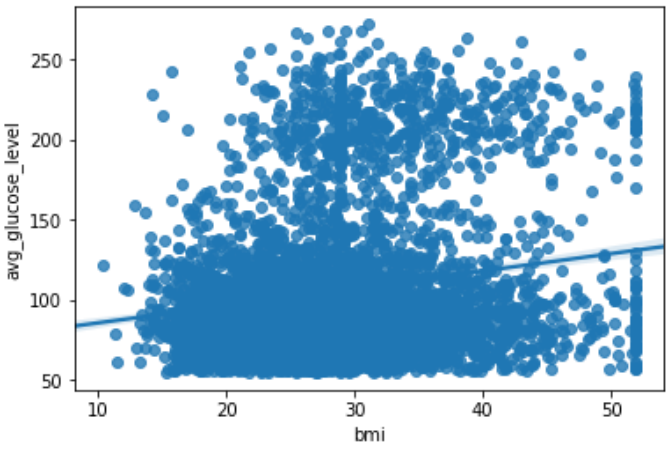

Построили график рассеяния, показывающий зависимость между двумя признаками: bmi - индекс массы тела и avg_glucose_level - уровнем глюкозы в крови

Вывод:

При выполнении рубежного контроля были воспроизведены следующие задачи:

1. Для набора данных проведено устранение пропусков для числового признака с использованием метода заполнения средним значением.
2. Для набора данных для числового признака проведено обнаружение и замена (найденными верхними и нижними границами) выбросов на основе правила трех сигм.
3. Для пары произвольных колонок данных построен график "Диаграмма рассеяния".