Московский государственный технический университет им. Н.Э. Баумана Факультет «Информатика и системы управления» Кафедра «Системы обработки информации и управления» Дисциплина «Технологии машинного обучения»

Отчёт

по лабораторной работе №3

«Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»

Вариант 12

Студент:

Крюков Г. М.

Группа ИУ5-61Б

Преподаватель:

Гапанюк Ю. Е.

Цель лабораторной работы:

Изучение способов предварительной обработки данных для дальнейшего формирования моделей.

Задание:

- Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
- Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
 - о обработку пропусков в данных;
 - о кодирование категориальных признаков;
 - о масштабирование данных.


Выполнение работы:

Выбранные датасеты:

https://www.kaggle.com/cigdev/formula-1-race-data-19502017?select=results.csv

https://www.kaggle.com/rohanrao/formula-1-world-championship-1950-2020?select=drivers.csv

1. Загрузка и первичный анализ данных



milliseconds float64 milliseconds 17774
fastestLap float64 fastestLap 18394
rank float64 rank 18246
fastestLapTime object fastestLapTime 18394

fastestLapSpeed object fastestLapSpeed 18394 statusId int64 statusId 0 dtype: object dtype: int64

2. Обработка пропусков в данных

2.1. Простые стратегии - удаление или заполнение нулями

```
# Удаление колонок, содержащих пустые значения data_new_1 = data.dropna(axis=1, how='any') (data.shape, data_new_1.shape)

((23777, 18), (23777, 10))

# Удаление строк, содержащих пустые значения data_new_2 = data.dropna(axis=0, how='any') (data.shape, data_new_2.shape)

((23777, 18), (2604, 18))
```

lata.he	ad()																	
res	ultId	raceId	driverId	constructorId	number	grid	position	positionText	positionOrder	points	laps	time	milliseconds	fastestLap	rank	fastestLapTime	fastestLapSpeed	statusI
0	1	18	1	1	22.0	1	1.0	1	1	10.0	58	34:50.6	5690616.0	39.0	2.0	01:27.5	218.3	
1	2	18	2	2	3.0	5	2.0	2	2	8.0	58	5.478	5696094.0	41.0	3.0	01:27.7	217.586	
2	3	18	3	3	7.0	7	3.0	3	3	6.0	58	8.163	5698779.0	41.0	5.0	01:28.1	216.719	
3	4	18	4	4	5.0	11	4.0	4	4	5.0	58	17.181	5707797.0	58.0	7.0	01:28.6	215.464	
4	5	18	5	1	23.0	3	5.0	5	5	4.0	58	18.014	5708630.0	43.0	1.0	01:27.4	218.385	
ata_ne	w_3 = d	data.fil		значений нулями														
ata_ne ata_ne	ew_3 = d ew_3.hea	data.fil ad()	llna(0)	·		gnid	norition	noritionText	noritionOrden	nointe	lane	tima	millieaconde	factorti an	nank	Exchant antimo	fartest answer	etatue
ata_ne ata_ne res	ew_3 = d ew_3.hea	data.fil ad() raceId	llna(0)	constructorId	number	grid		positionText	positionOrder								fastestLapSpeed	status
ata_ne ata_ne res	ew_3 = d ew_3.hea ultId 1	data.fil ad() raceId 18	lina(0) driverId	constructorId	number 22.0	1	1.0	1	1	10.0	58	34:50.6	5690616.0	39.0	2.0	01:27.5	218.3	status
ata_ne lata_ne res 0	ew_3 = d ew_3.hea ultId 1 2	data.fil ad() raceId 18	driverId 1 2	constructorId 1	number 22.0 3.0	1 5	1.0	1 2	1 2	10.0	58 58	34:50.6 5.478	5690616.0 5696094.0	39.0 41.0	2.0 3.0	01:27.5 01:27.7	218.3 217.586	status
res 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1	ew_3 = d ew_3.hea ultId 1	data.fil ad() raceId 18 18	driverId 1 2 3	constructorId	number 22.0 3.0 7.0	1 5 7	1.0 2.0 3.0	1	1 2 3	10.0 8.0 6.0	58 58 58	34:50.6 5.478 8.163	5690616.0 5696094.0 5698779.0	39.0 41.0 41.0	2.0 3.0 5.0	01:27.5 01:27.7 01:28.1	218.3 217.586 216.719	status
data_ne data_ne	ew_3 = dew_3.hea	data.fil ad() raceId 18	driverId 1 2	constructorId 1 2 3	number 22.0 3.0	1 5	1.0	1 2 3	1 2	10.0	58 58	34:50.6 5.478	5690616.0 5696094.0	39.0 41.0	2.0 3.0	01:27.5 01:27.7	218.3 217.586	status


2.2. "Внедрение значений" - импьютация (imputation)

```
# Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
       num_cols.append(col)
       temp_perc = round((temp_null_count / total_count) * 100.0, 2)
       print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_count, temp_perc))
Колонка number. Тип данных float64. Количество пустых значений 6, 0.03%.
Колонка position. Тип данных float64. Количество пустых значений 10550, 44.37%. 
Колонка milliseconds. Тип данных float64. Количество пустых значений 17774, 74.75%. 
Колонка fastestlap. Тип данных float64. Количество пустых значений 18394, 77.36%.
Колонка rank. Тип данных float64. Количество пустых значений 18246, 76.74%.
# Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
       number position milliseconds fastestLap rank
0 22.0 1.0 5690616.0 39.0 2.0
          3.0
                    2.0
                           5696094.0
                                            41.0 3.0
2 7.0 3.0 5698779.0 41.0 5.0
                   4.0 5707797.0
  3
          5.0
                                           58.0 7.0
4 23.0 5.0 5708630.0 43.0 1.0
23772 10.0 16.0 NaN 33.0 16.0
23773
                                            36.0 15.0
        9.0
                 17.0
                                NaN
                              NaN
23774 18.0 18.0
                                           52.0 6.0
23775
        55.0
                 NaN
                                 NaN
                                            26.0 14.0
23776 3.0 NaN NaN
                                          13.0 12.0
23777 rows x 5 columns
```

```
# Гистограмма по признакам
for col in data_num:
   plt.hist(data[col], 50)
   plt.xlabel(col)
   plt.show()
```

/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:839: RuntimeWarning: invalid value encountered in greater_equal keep = (tmp_a >= first_edge)
/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:840: RuntimeWarning: invalid value encountered in less_equal

'usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:840: RuntimeWarning: invalid value encountered in less_equa. keep &= (tmp_a <= last_edge)



Фильтр по пустым значениям поля salary data[data['position'].isnull()]

resultId raceId driverId constructorId number grid position positionText positionOrder points laps time milliseconds fastestiap rank fastestiapTime fastestiapSpeed statusId 8 9 18 9 2 4.0 2 NaN R 9 0.0 47 NaN NaN 15.0 9.0 01:28.8 215.1 4 10 18 10 12.0 18 NaN R 10 0.0 43 NaN NaN 23.0 13.0 01:29 6 213 166 NaN 24.0 15.0 10 11 18 11 11 0.0 32 NaN 8 18.0 19 NaN R 01:30.9 210.038 11 12 18 12 6.0 20 NaN 12 0.0 30 NaN NaN 20.0 16.0 01:31.4 208.907 12 13 18 13 6 2.0 4 NaN 13 0.0 29 NaN NaN 23.0 6.0 01:28.2 216.51 23754 23759 987 10 31.0 10 18 0.0 0 NaN 23755 2.0 0.0 NaN NaN 23756 23761 987 825 210 20.0 13 NaN 20 0.0 0 NaN NaN NaN 0.0 NaN NaN 01:43.4 193.41 23775 23780 988 832 55.0 12 NaN 19 0.0 31 NaN NaN 26.0 14.0 36 23776 23781 988 817 20 0.0 20 NaN NaN 13.0 12.0 9 3.0 4 NaN 01:42.8 194.579

10550 rows × 18 columns

```
# Запоминаем индексы строк с пустыми значениями
flt_index = data[data['position'].isnull()].index
flt_index

Int64Index([ 8, 9, 10, 11, 12, 13, 14, 15, 16,
17,
```

... 23733, 23734, 23735, 23736, 23753, 23754, 23755, 23756, 23775, 23776], dtype='int64', length=10550)

Проверяем что выводятся нужные строки data[data.index.isin(flt_index)]

antalat			2															
	resultId	raceId	driverId	constructorId	number	grid	position	positionText	positionOrder	points	laps	time	milliseconds	fastestLap	rank	fastestLapTime	fastestLapSpeed	statusId
8	9	18	9	2	4.0	2	NaN	R	9	0.0	47	NaN	NaN	15.0	9.0	01:28.8	215.1	4
9	10	18	10	7	12.0	18	NaN	R	10	0.0	43	NaN	NaN	23.0	13.0	01:29.6	213.166	3
10	11	18	11	8	18.0	19	NaN	R	11	0.0	32	NaN	NaN	24.0	15.0	01:30.9	210.038	7
11	12	18	12	4	6.0	20	NaN	R	12	0.0	30	NaN	NaN	20.0	16.0	01:31.4	208.907	8
12	13	18	13	6	2.0	4	NaN	R	13	0.0	29	NaN	NaN	23.0	6.0	01:28.2	216.51	5
23754	23759	987	839	10	31.0	10	NaN	R	18	0.0	0	NaN	NaN	NaN	0.0	NaN	NaN	3
23755	23760	987	838	1	2.0	12	NaN	R	19	0.0	0	NaN	NaN	NaN	0.0	NaN	NaN	3
23756	23761	987	825	210	20.0	13	NaN	R	20	0.0	0	NaN	NaN	NaN	0.0	NaN	NaN	3
23775	23780	988	832	4	55.0	12	NaN	R	19	0.0	31	NaN	NaN	26.0	14.0	01:43.4	193.41	36
23776	23781	988	817	9	3.0	4	NaN	R	20	0.0	20	NaN	NaN	13.0	12.0	01:42.8	194.579	9

10550 rows × 18 columns

```
# фильтр по колонке
         data_num[data_num.index.isin(flt_index)]['position']
        8
                NaN
        9
                NaN
        10
                NaN
        11
                NaN
        12
                NaN
        23754 NaN
        23755 NaN
         23756
                NaN
        23775
                NaN
        23776 NaN
        Name: position, Length: 10550, dtype: float64
        data_num_position = data_num[['position']]
        data_num_position.head()
            position
         0
                1.0
                  2.0
         1
         2
                  3.0
         3
                  4.0
                  5.0
        from sklearn.impute import SimpleImputer
        from sklearn.impute import MissingIndicator
 # Фильтр для проверки заполнения пустых значений
indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(data_num_position)
mask_missing_values_only
array([[False],
        [False],
        [False],
        [False],
        [ True],
        [ True]])
strategies=['mean', 'median', 'most_frequent']
def test_num_impute(strategy_param):
   imp_num = SimpleImputer(strategy=strategy_param)
   data_num_imp = imp_num.fit_transform(data_num_position)
   return data_num_imp[mask_missing_values_only]
strategies[0], test_num_impute(strategies[0])
('mean',
array([7.78226355, 7.78226355, 7.78226355, ..., 7.78226355, 7.78226355,
       7.78226355]))
```

```
strategies[1], test_num_impute(strategies[1])
('median', array([7., 7., 7., ..., 7., 7.]))
strategies[2], test_num_impute(strategies[2])
('most_frequent', array([3., 3., 3., ..., 3., 3., 3.]))
```

```
# Более сложная функция, которая позволяет задавать колонку и вид импьютации

def test_num_impute_col(dataset, column, strategy_param):
    temp_data = dataset[[column]]

indicator = MissingIndicator()
    mask_missing_values_only = indicator.fit_transform(temp_data)

imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(temp_data)

filled_data = data_num_imp[mask_missing_values_only]

return column, strategy_param, filled_data.size, filled_data[0], filled_data
[filled_data.size-1]
```

data[['position']].describe()

	position
count	13227.000000
mean	7.782264
std	4.745105
min	1.000000
25%	4.000000
50%	7.000000
75%	11.000000
max	33.000000

```
test_num_impute_col(data, 'position', strategies[0])
('position', 'mean', 10550, 7.782263551825811, 7.782263551825811)

test_num_impute_col(data, 'position', strategies[1])
('position', 'median', 10550, 7.0, 7.0)

test_num_impute_col(data, 'position', strategies[2])
('position', 'most_frequent', 10550, 3.0, 3.0)
```

```
3. Преобразование категориальных признаков в числовые
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
data = pd.read_csv('/content/datasets_468218_878459_drivers.csv')
data.head()
   driverId driverRef number code forename surname dob nationality
                                                                                                      url
0
   1 hamilton 44 HAM Lewis Hamilton 1985-01-07
                                                                  British http://en.wikipedia.org/wiki/Lewis_Hamilton
                        \N HEI
                                    Nick Heidfeld 1977-05-10
                                                                            http://en.wikipedia.org/wiki/Nick_Heidfeld
1
         2 heidfeld
                                                                 German
     3 rosberg 6 ROS Nico Rosberg 1985-06-27 German
                                                                           http://en.wikipedia.org/wiki/Nico_Rosberg
2
3
            alonso 14 ALO Fernando Alonso 1981-07-29
                                                                 Spanish http://en.wikipedia.org/wiki/Fernando_Alonso
      5 kovalainen \N KOV Heikki Kovalainen 1981-10-19
                                                                 Finnish http://en.wikipedia.org/wiki/Heikki_Kovalainen
le = LabelEncoder()
cat_temp_data = data[['nationality']]
cat_temp_data.head()
   nationality
0
      British
1
       German
2
    German
       Spanish
3
      Finnish
             imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
             data_imp2 = imp2.fit_transform(cat_temp_data)
             cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
             cat_enc
```

	c1
0	British
1	German
2	German
3	Spanish
4	Finnish
842	Monegasque
843	Russian
844	British
845	British
846	Thai
847 rd	ws × 1 columns

3.1. Кодирование категорий целочисленными значениями - label encoding

3.2. Кодирование категорий наборами бинарных значений - one-hot encoding

```
ohe = OneHotEncoder()
cat_enc_ohe = ohe.fit_transform(cat_enc[['c1']])
cat_enc.shape
(847, 1)
cat_enc_ohe.shape
(847, 41)
cat enc ohe
<847x41 sparse matrix of type '<class 'numpy.float64'>'
    with 847 stored elements in Compressed Sparse Row format>
 cat_enc_ohe.todense()[0:10]
 matrix([[0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0.,
     0., 0., 0., 0., 0., 0., 0., 0., 0.],
     0., 0., 0., 0., 0., 0., 0., 0., 0.],
     0., 0., 0., 1., 0., 0., 0., 0., 0.],
     0., 0., 0., 0., 0., 0., 0., 0., 0.],
     0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0.,
     0., 0., 0., 0., 0., 0., 0., 0., 0.],
     0., 0., 0., 0., 0., 0., 0., 0., 0.],
    0., 0., 0., 0., 0., 0., 0., 0.],
     cat_enc.head(10)
  0
    British
  1
   German
 2
   German
  3
   Spanish
    Finnish
  5 Japanese
  6
    French
    Finnish
    Polish
  8
   German
```

3.3. Pandas get_dummies - быстрый вариант one-hot кодирования

	c1_American	c1_American- Italian	c1_Argentine	c1_Argentine- Italian	c1_Australian	c1_Austrian	c1_Belgian	c1_Brazilian	c1_British	c1_Canadian	c1_Chilean	c1_Colombi
)	0	0	0	0	0	0	0	0	1	0	0	
	0	0	0	0	0	0	0	0	0	0	0	
	0	0	0	0	0	0	0	0	0	0	0	
	0	0	0	0	0	0	0	0	0	0	0	
	0	0	0	0	0	0	0	0	0	0	0	
_			dummy_na=True	, ,,								
_				can- nationalis	ty_Argentine ⁿ	ationality_Arg	entine- _{nat}	tionality_Austr	ralian natio	onality_Austri	an national	lity_Belgi
_			ionality_Americ	can- nationalis	ty_Argentine ⁿ	ationality_Arg	entine- nat Italian	tionality_Austr	ralian natio	onality_Austri	ian national	lity_Belgi
		American nat	ionality_Americ	can- nationali		ationality_Arg	Italian	tionality_Austr		onality_Austri		lity_Belgi
		American nat	ionality_Americ	can- nationali 0	0	ationality_Arg	0	tionality_Austr	0	onality_Austri	0	lity_Belgi
_		American nat	ionality_Americ	can- lian nationali	0	ationality_Arg	0 0	tionality_Austr	0	onality_Austri	0	lity_Belgi

4. Масштабирование данных

from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer

4.1. МіпМах масштабирование

0.6

0.8

```
data = pd.read_csv('/content/results.csv')
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['milliseconds']])
plt.hist(data['milliseconds'], 50)
plt.show()
/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:839: RuntimeWarning: invalid value encountered in greater_equal
keep = (tmp_a >= first_edge)
/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:840: RuntimeWarning: invalid value encountered in less_equal
  keep &= (tmp_a <= last_edge)
1000
        0.2
```

```
plt.hist(sc1_data, 50)
plt.show()

/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.
keep = (tmp_a >= first_edge)
/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.
keep &= (tmp_a <= last_edge)

1000

800

600

400

0.0

0.2

0.4

0.6

0.8

1.0
```

4.2. Масштабирование данных на основе Z-оценки – StandardScaler

```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['positionOrder']])
plt.hist(sc2_data, 50)
plt.show()
```

4.3. Нормализация данных

200